



## هوش مصنوعی

دانشکده مهندسی کامپیوتر

بهار ۱۴۰۴

۱ شهریور ۱۴۰۴

### امتحان پایانترم

زمان آزمون: ۱۲۰ دقیقه

۱. لطفا پاسخ خود را با خط خوانا بنویسید.

۲. پاسخ هر سوال را در یک صفحه جدا و شماره پرسش را به صورت واضح در بالای هر صفحه بنویسید.

۳. آزمون از ۱۱۰ نمره است. دریافت ۱۰۰ نمره از ۱۱۰ نمره به منزله دریافت نمره کامل خواهد بود. نمره بالای ۱۰۰ سرریز نخواهد کرد.

۴. نوشته‌های شما در قسمت چرک‌نویس به هیچ عنوان تصحیح نخواهد شد.

۵. استفاده از منابع و لوازم الکترونیکی حین پاسخگویی به سوالات آزمون غیرمجاز است.

### پرسش‌های آزمون (۱۱۰ نمره)

پرسش ۱ (۲۳ نمره) درستی یا نادرستی موارد زیر را همراه با ذکر دلیل مشخص کنید

(آ) (۳ نمره) الگوریتم  $Q-learning$  می‌تواند تابع بهینه  $Q$  یا همان  $Q^*$  را بدون اجرای سیاست بهینه یا همان  $\pi^*$ ، یاد بگیرد.

(ب) (۳ نمره) الگوریتم Value iteration تضمین به همگرایی می‌دهد در صورتی که ضریب تخفیف ( $\gamma$ ) در نابرابری  $0 < \gamma < 1$  قرار گیرد

(ج) (۳ نمره) در الگوریتم approximate  $Q-learning$  اگر نرخ یادگیری ( $\alpha$ ) و ضریب تخفیف ( $\gamma$ ) هر دو کاهش یابند، مقادیر  $Q$  به پاداش اخیر حساس‌تر می‌شوند.

(د) (۳ نمره) در صورتی که داده‌های آموزش بدون نویز باشند یک درخت تصمیم در صورتی که اجازه داده شود بدون شرط توقف و محدودیتی روی عمق رشد کند، توانایی دارد که هر داده آموزشی را با دقت ۱۰۰ درصد دسته‌بندی کند ولی ممکن است نتواند Generalize کند.

(ه) (۳ نمره) در هنگام استفاده از یک مدل Naive Bayes به همراه Laplace Smoothing با افزایش مقدار  $K$  مقدار خطای آموزش می‌تواند افزایش و مقدار خطای تست می‌تواند افزایش یابد.

(و) (۴ نمره) در یک MDP با حالات محدود و پاداش با باند مشخص و  $0 < \gamma < 1$  در صورتی همه پاداش‌ها با عدد ثابت  $c$  جمع شود، سیاست بهینه تغییر نمی‌کند.

(ز) (۴ نمره) اگر بدانیم که  $|S| \gg |A|$  آنگاه پیچیدگی زمانی هر iteration در policy iteration و value iteration باهم برابر می‌شود.

### پاسخ

(آ) درست است: قابل توجه است که الگوریتم  $Q-learning$  در واقع یک یادگیری Off-policy است. در رویکرد Off-policy سیاست بهینه بدون در نظر گرفتن اقدامات عامل یا انگیزه آن برای اقدام بعدی تعیین می‌شود. به عبارتی می‌توان مقدار اقدام بهینه را بدون نیاز به اجرای سیاست بهینه در تمام طول الگوریتم تعیین کند.

(ب) درست است: دلیل آن این است که وقتی  $\gamma$  در این محدوده باشد، پاداش‌های آینده‌تر به درستی تخفیف داده می‌شوند (تزیل می‌شوند) و این اطمینان را می‌دهد که الگوریتم می‌تواند به درستی بین پاداش‌های نزدیک و آینده تعادل برقرار کند. این اتفاق اجازه می‌دهد تا الگوریتم به یک راه حل منحصر به فرد همگرا شود، مشروط بر اینکه  $MDP$  محدود و ثابت باشد.

(ج) نادرست است: چرا که با کاهش  $\gamma$  پاداش‌های اخیر تأثیر کمتری نسبت به قبل می‌دهیم و همچنین با کاهش  $\alpha$  فرآیند یادگیری را کندتر کرده‌ایم.

(د) درست است: درخت تصمیم با توجه به فرایند ساخته شدنش تا جایی پیش می‌رود که داده‌های رسیده به برگ‌ها فقط از یک دسته باشد و بنابراین روی داده آموزشی به دقت ۱۰۰ درصد دست می‌یابد. بدین علت چنین درختی ممکن است به علت واریانس بالا، روی داده‌های جدید عملکرد خوبی نداشته باشد.

(ه) درست است: هر دو می‌تواند رخ دهند. با افزایش مقدار  $K$  مدل کمتر روی داده‌های آموزشی فیت می‌شود که سبب می‌شود خطای آموزش افزایش یابد. و در صورتی که مقدار  $K$  بیش از اندازه افزایش یابد مدل بیش از اندازه هموار خواهد شد که باعث عملکرد ضعیف آن underfit خواهد شد.

(و) درست است: افزودن یک مقدار ثابت به تمام پاداش‌ها تأثیری بر روی ترتیب نسبی ارزش‌های حالت‌ها ندارد. (اگر فرض می‌کردیم که MDP می‌تواند یک استیت Terminal داشته باشد، گزاره غلط می‌شد. پس به جواب‌هایی که برای این حالت مثال نقض آورده‌اند نیز نمره داده می‌شود.)

(ز) نادرست است: در صورتی که تعداد حالت‌ها بسیار بیشتر از تعداد اقدامات باشد، پیچیدگی زمانی این دو الگوریتم می‌تواند متفاوت باشد. اردر زمانی value iteration برابر است با  $|S|^2|A|$  و برای policy iteration برابر است با  $|S|^2|A| + |S|^3$

در این مسئله، ما به تخمین گر maximum likelihood با استفاده از naive bayes می پردازیم. در اینجا، ویژگی های باینری  $x_j$ ,  $j = 1, \dots, n$  در مدل ما متغیرهای گسسته و دودویی هستند، یعنی  $x_j \in \{0, 1\}$  و  $x = [x_1 \ x_2 \ \dots \ x_n]^T$  را به عنوان بردار ورودی در نظر می گیریم. برای هر نمونه آموزشی، خروجی های ما یک مقدار دودویی منفرد  $y \in \{0, 1\}$  هستند. مدل ما با پارامترهای  $(x, y)$  مشترک را بر اساس موارد زیر مدل سازی می کنیم:

$$\begin{aligned} p(y) &= (\phi_y)^y (1 - \phi_y)^{1-y} \\ p(x | y = 0) &= \prod_{j=1}^n p(x_j | y = 0) \\ &= \prod_{j=1}^n (\phi_{j|y=0})^{x_j} (1 - \phi_{j|y=0})^{1-x_j} \\ p(x | y = 1) &= \prod_{j=1}^n p(x_j | y = 1) \\ &= \prod_{j=1}^n (\phi_{j|y=1})^{x_j} (1 - \phi_{j|y=1})^{1-x_j} \end{aligned}$$

(آ) (۴ نمره) تابع likelihood مشترک

$$\ell(\varphi) = \log \prod_{i=1}^m p(x^{(i)}, y^{(i)}; \varphi)$$

را بر حسب پارامترهای مدل داده شده در بالا بیابید.  $\varphi$  کل مجموعه پارامترها را نشان می دهد:

$$\{\phi_y, \phi_{j|y=0}, \phi_{j|y=1}, j = 1, \dots, n\}.$$

(ب) (۴ نمره) نشان دهید پارامترهایی که تابع likelihood را بیشینه می کنند به صورت زیر هستند:

$$\begin{aligned} \phi_{j|y=0} &= \frac{\sum_{i=1}^m \mathbb{1}\{x_j^{(i)} = 1 \wedge y^{(i)} = 0\}}{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 0\}} \\ \phi_{j|y=1} &= \frac{\sum_{i=1}^m \mathbb{1}\{x_j^{(i)} = 1 \wedge y^{(i)} = 1\}}{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 1\}} \\ \phi_y &= \frac{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 1\}}{m}. \end{aligned}$$

(ج) (۷ نمره) در نظر بگیرید که می خواهیم پیش بینی ای روی یک داده ی جدید  $x$  با استفاده از محتمل ترین برچسب کلاسی که توسط الگوریتم naive bayes تولید می شود، انجام دهیم. نشان دهید اگر  $p(y = 0 | x)$  و  $p(y = 1 | x)$  احتمالات کلاس بازگردانده شده توسط naive bayes باشند، برداری  $\theta \in \mathbb{R}^{n+1}$  وجود دارد به طوری که

$$p(y = 1 | x) \geq p(y = 0 | x) \quad \text{اگر و تنها اگر} \quad \theta^T \begin{bmatrix} 1 \\ x \end{bmatrix} \geq 0.$$

بردار  $\theta$  را بیابید همچنین  $\theta$  را جمله ثابت در نظر بگیرید

پاسخ

$$\begin{aligned}
\ell(\varphi) &= \log \prod_{i=1}^m p(x^{(i)}, y^{(i)}; \varphi) \\
&= \log \prod_{i=1}^m p(x^{(i)}|y^{(i)}; \varphi) p(y^{(i)}; \varphi) \\
&= \log \prod_{i=1}^m \left( \prod_{j=1}^n p(x_j^{(i)}|y^{(i)}; \varphi) \right) p(y^{(i)}; \varphi) \\
&= \sum_{i=1}^m \left( \log p(y^{(i)}; \varphi) + \sum_{j=1}^n \log p(x_j^{(i)}|y^{(i)}; \varphi) \right) \\
&= \sum_{i=1}^m \left[ y^{(i)} \log \phi_y + (1 - y^{(i)}) \log(1 - \phi_y) \right. \\
&\quad \left. + \sum_{j=1}^n \left( x_j^{(i)} \log \phi_{j|y^{(i)}} + (1 - x_j^{(i)}) \log(1 - \phi_{j|y^{(i)}}) \right) \right]
\end{aligned}$$

(ب) تنها جمله‌هایی در  $\ell(\varphi)$  که گرادیان غیر صفر نسبت به  $\phi_{j|y=0}$  دارند، آن‌هایی هستند که شامل  $\phi_{j|y^{(i)}}$  می‌شوند. بنابراین:

$$\begin{aligned}
\nabla_{\phi_{j|y=0}} \ell(\varphi) &= \nabla_{\phi_{j|y=0}} \sum_{i=1}^m \left( x_j^{(i)} \log \phi_{j|y^{(i)}} + (1 - x_j^{(i)}) \log(1 - \phi_{j|y^{(i)}}) \right) \\
&= \nabla_{\phi_{j|y=0}} \sum_{i=1}^m \left( x_j^{(i)} \log(\phi_{j|y=0}) \mathbb{1}\{y^{(i)} = 0\} + (1 - x_j^{(i)}) \log(1 - \phi_{j|y=0}) \mathbb{1}\{y^{(i)} = 0\} \right) \\
&= \sum_{i=1}^m \left( \frac{x_j^{(i)}}{\phi_{j|y=0}} \mathbb{1}\{y^{(i)} = 0\} - \frac{1 - x_j^{(i)}}{1 - \phi_{j|y=0}} \mathbb{1}\{y^{(i)} = 0\} \right).
\end{aligned}$$

با قرار دادن  $\nabla_{\phi_{j|y=0}} \ell(\varphi) = 0$  داریم:

$$\begin{aligned}
0 &= \sum_{i=1}^m \left( \frac{x_j^{(i)}}{\phi_{j|y=0}} \mathbb{1}\{y^{(i)} = 0\} - \frac{1 - x_j^{(i)}}{1 - \phi_{j|y=0}} \mathbb{1}\{y^{(i)} = 0\} \right) \\
&= \sum_{i=1}^m \left( x_j^{(i)} (1 - \phi_{j|y=0}) \mathbb{1}\{y^{(i)} = 0\} - (1 - x_j^{(i)}) \phi_{j|y=0} \mathbb{1}\{y^{(i)} = 0\} \right) \\
&= \sum_{i=1}^m \left( (x_j^{(i)} - \phi_{j|y=0}) \mathbb{1}\{y^{(i)} = 0\} \right) \\
&= \sum_{i=1}^m x_j^{(i)} \mathbb{1}\{y^{(i)} = 0\} - \phi_{j|y=0} \sum_{i=1}^m \mathbb{1}\{y^{(i)} = 0\} \\
&= \sum_{i=1}^m \mathbb{1}\{x_j^{(i)} = 1 \wedge y^{(i)} = 0\} - \phi_{j|y=0} \sum_{i=1}^m \mathbb{1}\{y^{(i)} = 0\}.
\end{aligned}$$

در نتیجه به جواب مطلوب خود می‌رسیم:

$$\phi_{j|y=0} = \frac{\sum_{i=1}^m \mathbb{1}\{x_j^{(i)} = 1 \wedge y^{(i)} = 0\}}{\sum_{i=1}^m \mathbb{1}\{y^{(i)} = 0\}}.$$

راحل برای  $\phi_{j|y=1}$  نیز به همان روش به دست می‌آید.  
برای حل  $\phi_y$ ,

$$\begin{aligned}
\nabla_{\phi_y} \ell(\varphi) &= \nabla_{\phi_y} \sum_{i=1}^m \left( y^{(i)} \log \phi_y + (1 - y^{(i)}) \log(1 - \phi_y) \right) \\
&= \sum_{i=1}^m \left( y^{(i)} \frac{1}{\phi_y} - (1 - y^{(i)}) \frac{1}{1 - \phi_y} \right).
\end{aligned}$$

سپس با قرار دادن  $\nabla_{\phi_y} \ell(\varphi) = \bullet$  خواهیم داشت

$$\begin{aligned} \bullet &= \sum_{i=1}^m \left( y^{(i)} \frac{1}{\phi_y} - (1 - y^{(i)}) \frac{1}{1 - \phi_y} \right) \\ &= \sum_{i=1}^m \left( y^{(i)} (1 - \phi_y) - (1 - y^{(i)}) \phi_y \right) \\ &= \sum_{i=1}^m y^{(i)} - \sum_{i=1}^m \phi_y \\ &= \sum_{i=1}^m y^{(i)} - m \phi_y. \end{aligned}$$

در نتیجه،

$$\phi_y = \frac{\sum_{i=1}^m 1\{y^{(i)} = 1\}}{m}.$$

(ج)

$$\begin{aligned} p(y = 1|x) &\geq p(y = \bullet|x) \\ \iff \frac{p(y = 1|x)}{p(y = \bullet|x)} &\geq 1 \\ \iff \frac{\left(\prod_{j=1}^n p(x_j|y = 1)\right) p(y = 1)}{\left(\prod_{j=1}^n p(x_j|y = \bullet)\right) p(y = \bullet)} &\geq 1 \\ \iff \frac{\left(\prod_{j=1}^n (\phi_{j|y=\bullet})^{x_j} (1 - \phi_{j|y=\bullet})^{1-x_j}\right) \phi_y}{\left(\prod_{j=1}^n (\phi_{j|y=1})^{x_j} (1 - \phi_{j|y=1})^{1-x_j}\right) (1 - \phi_y)} &\geq 1 \\ \iff \sum_{j=1}^n \left( x_j \log \left( \frac{\phi_{j|y=1}}{\phi_{j|y=\bullet}} \right) + (1 - x_j) \log \left( \frac{1 - \phi_{j|y=\bullet}}{1 - \phi_{j|y=1}} \right) \right) + \log \left( \frac{\phi_y}{1 - \phi_y} \right) &\geq \bullet \\ \iff \sum_{j=1}^n x_j \log \left( \frac{\phi_{j|y=1} (1 - \phi_{j|y=\bullet})}{\phi_{j|y=\bullet} (1 - \phi_{j|y=1})} \right) + \sum_{j=1}^n \log \left( \frac{1 - \phi_{j|y=1}}{1 - \phi_{j|y=\bullet}} \right) + \log \left( \frac{\phi_y}{1 - \phi_y} \right) &\geq \bullet \\ \iff \theta^T \begin{bmatrix} 1 \\ x \end{bmatrix} &\geq \bullet \end{aligned}$$

که

$$\begin{aligned} \theta_{\bullet} &= \sum_{j=1}^n \log \left( \frac{1 - \phi_{j|y=\bullet}}{1 - \phi_{j|y=1}} \right) + \log \left( \frac{\phi_y}{1 - \phi_y} \right) \\ \theta_j &= \log \left( \frac{(\phi_{j|y=1})(1 - \phi_{j|y=\bullet})}{(\phi_{j|y=\bullet})(1 - \phi_{j|y=1})} \right), \quad j = 1, \dots, n. \end{aligned}$$

پرسش ۳ (۱۵ نمره) دو مدل زیر از رگرسیون لجستیک را برای یک دسته‌بندی دودویی با تابع سیگموید در نظر بگیرید

$$g(z) = \frac{1}{1 + e^{-z}} :$$

• مدل ۱:

$$P(Y = 1 | X, w_1, w_2) = g(w_1 X_1 + w_2 X_2)$$

• مدل ۲:

$$P(Y = 1 | X, w_1, w_2) = g(w_{\bullet} + w_1 X_1 + w_2 X_2)$$

ما سه نمونه‌ی آموزشی داریم:

$$\begin{aligned} x^{(1)} &= [1, 1]^T, & x^{(2)} &= [1, \bullet]^T, & x^{(3)} &= [\bullet, \bullet]^T \\ y^{(1)} &= 1, & y^{(2)} &= -1, & y^{(3)} &= 1 \end{aligned}$$

(آ) (۷نمره) آیا مهم است که نمونه‌ی سوم در مدل ۱ چه برجسی داشته باشد؟ یعنی اگر برجسب نمونه‌ی سوم را به ۱- تغییر دهیم، آیا مقدار آموخته‌شده‌ی  $\mathbf{w} = (w_1, w_2)$  متفاوت خواهد شد؟ آیا در مدل ۲ مهم است؟ پاسخ خود را به طور خلاصه توضیح دهید. (راهنما: به مرز تصمیم روی صفحه‌ی دویعدی فکر کنید.)

(ب) (۸نمره) اکنون فرض کنید مدل رگرسیون لجستیک (مدل ۲) را بر اساس  $n$  نمونه‌ی آموزشی  $x^{(1)}, \dots, x^{(n)}$  و برجسب‌ها  $y^{(1)}, \dots, y^{(n)}$  با بیشینه‌سازی log-likelihood جریمه‌دار زیر آموزش دهیم:

$$\sum_i \log P(y^{(i)} | x^{(i)}, \mathbf{w}) - \frac{\lambda}{2} \|\mathbf{w}\|^2 = \sum_i \log g(y^{(i)} \mathbf{w}^T x^{(i)}) - \frac{\lambda}{2} \|\mathbf{w}\|^2$$

برای  $\lambda$  بزرگ، جمله‌های log-likelihood به صورت توابع خطی از  $\mathbf{w}$  رفتار می‌کنند:

$$\log g(y^{(i)} \mathbf{w}^T x^{(i)}) \approx \frac{1}{2} y^{(i)} \mathbf{w}^T x^{(i)}.$$

log-likelihood جریمه‌دار را با استفاده از این تقریب (در مدل ۱) بیان کنید، و عبارت برآوردگر MLE  $\hat{\mathbf{w}}$  را بر حسب  $\lambda$  و داده‌های آموزشی  $\{x^{(i)}, y^{(i)}\}_{i=1}^n$  به دست آورید. بر اساس این، توضیح دهید  $\mathbf{w}$  با افزایش  $\lambda$  چگونه رفتار می‌کند. (فرض کنید هر  $x^{(i)} = (x_1^{(i)}, x_2^{(i)})^T$  و  $y^{(i)}$  یا ۱ است یا -۱.)

پاسخ

(آ) (۱) در مدل ۱ اهمیتی ندارد، زیرا  $x^{(3)} = (0, 0)$  باعث می‌شود که  $w_1 x_1 + w_2 x_2$  صفر باشد و بنابراین likelihood مدل به مقدار  $\mathbf{w}$  وابسته نباشد. اما در مدل ۲ اهمیت دارد.

(ب)

$$\log l(\mathbf{w}) \approx \sum_i \frac{1}{2} y^{(i)} \mathbf{w}^T \mathbf{x}^{(i)} - \frac{\lambda}{2} \|\mathbf{w}\|^2$$


$$\frac{\partial}{\partial w_1} \log l(\mathbf{w}) \approx \frac{1}{2} \sum_i y^{(i)} x_1^{(i)} - \lambda w_1 = 0$$

$$\frac{\partial}{\partial w_2} \log l(\mathbf{w}) \approx \frac{1}{2} \sum_i y^{(i)} x_2^{(i)} - \lambda w_2 = 0$$

$$\mathbf{w} = \frac{1}{2\lambda} \sum_i y^{(i)} \mathbf{x}^{(i)}$$

پرسش ۴ (۲۴ نمره)

محیط زیر را در نظر بگیرید. در هر یک از استیت‌ها عامل می‌تواند یکی از کنش‌های بالا، پایین، چپ و راست را به طور قطعی انجام دهد و به استیت هدف برسد. همچنین اگر یک کنش موجب شود عامل از محیط خارج شود، آن کنش انجام نمی‌شود و عامل سر جای خود باقی می‌ماند. استیت‌هایی که در محیط زیر با عدد مشخص شده‌اند، استیت‌های ترمینال هستند و با ورود عامل به آنها، پاداشی برابر با عدد داخل آنها دریافت می‌کند. ورود به سایر حالات پاداشی برابر صفر خواهد داشت. همچنین فرض کنید که ضریب تخفیف  $\gamma$  برابر 0.5 است، نرخ یادگیری  $\alpha$  برابر 0.5 است. همچنین فرض کنید عامل از خانه (۱،۳) شروع به کار می‌کند.

3		-80	+100
2			
1	+25	-100	+80
	1	2	3

(آ) (۶نمره)

مقدار  $V^*((1, 2))$  و  $V^*((2, 2))$ ،  $V^*((3, 2))$ ،  $V^*((3, 2))$  را بدست آورید. همچنین بر اساس این مقادیر، سیاست بهینه را برای این سه استیت تعیین کنید. اکنون می‌خواهیم با استفاده از روش Approximate Q-Learning این مساله را بررسی کنیم. مجموعه فیچرها و وزن‌های اولیه آنها در پایین داده شده است.

Feature	Initial Weight ( $w_i$ )
$f_0(s, a) = 1$ (Bias feature)	$1.0$
$f_1(s, a) = \begin{cases} 1 & a=\text{Left} \\ 2 & a=\text{Right} \\ 0 & \text{otherwise.} \end{cases}$	$2.0$
$f_2(s, a) = \begin{cases} 1 & a=\text{Up} \\ 1 & a=\text{Down} \\ 0 & \text{otherwise.} \end{cases}$	$5.0$

(ب) (۶نمره) با توجه به نمونه  $[s, a, s', r] = [(3, 2), Up, (3, 3), 1.0]$  وزن‌ها را آپدیت کنید و مقدار  $Q((2, 2), Up)$  و  $Q((3, 2), Up)$  را محاسبه کنید.

(ج) (۶نمره) حالا فرض کنید که وزن‌ها به تعداد  $n$  بار آپدیت می‌شوند و بردار  $\vec{w}$  حاصل می‌شود. بردار وزن‌ها و کنش  $a$  به ازای  $Q_{\vec{w}}((2, 2), a)$  برقرار است؟ توضیح دهید.

(د) (۶نمره) با توجه به بخش‌های قبلی، آیا الگوریتم Approximate Q-Learning در این مساله می‌تواند به سیاست بهینه همگرا شود؟ توضیح دهید.

پاسخ

(ا)

$$V^*((3, 2)) = 1.0$$

$$V^*((2, 2)) = 0 + \gamma 1.0 = 0.5$$

$$V^*((1, 2)) = 0 + \gamma^2 1.0 = 0.25$$

بنابراین سیاست بهینه به شکل زیر خواهد بود. توجه شود برای حالت  $(1, 2)$  دو کنش وجود دارند که action-value function آنها برابر با مقدار  $V^*$  می‌شود.

$$\pi((3, 2)) = \text{Up}$$

$$\pi((2, 2)) = \text{Right}$$

$$\pi((1, 2)) = \text{Down or Right}$$

(ب) توجه شود استیت  $(3, 3)$  یک استیت ترمینال است و بنابراین:  $Q((3, 3), a) = 0$  است.

$$\text{Difference} = r + \gamma \max_{a'} Q(s', a') - Q(s, a)$$

$$= 1.0 + 0.5 \times 0 - 0.6 = 0.4$$

$$w_0 = 1.0 + 0.5(\text{difference})f_0((3, 2), Up) = 3.0$$

$$w_1 = 2.0 + 0.5(\text{difference})f_1((3, 2), Up) = 2.0$$

$$w_2 = 5.0 + 0.5(\text{difference})f_2((3, 2), Up) = 7.0$$

$$Q((3, 2), Up) = 3.0 + 0 + 7.0 = 10.0$$

$$Q((2, 2), Up) = 3.0 + 0 + 7.0 = 10.0$$

(ج) این تساوی همواره برقرار خواهد بود، چون فیچرهای استفاده‌شده به استیت عامل وابسته نیستند و به‌ازای یک کنش یکسان، مقدار  $Q$  ها برابر خواهد بود توجه شود که  $Q(s, a) = \sum_i w_i f_i(s, a)$

(د) با توجه به بخش قبل می‌توان نتیجه گرفت که سیاست به‌دست‌آمده با این الگوریتم برای همه استیت‌ها یکسان خواهد بود؛ زیرا  $\pi(s) = \arg \max_a Q(s, a)$  و طبق بخش قبل برای تمام استیت‌ها، به‌ازای یک کنش خاص، مقدار  $Q$  برابر خواهند داشت؛ پس اگر در یک استیت یک کنش مقدار  $Q$  بیشینه شود، این شرایط در سایر استیت‌ها نیز برقرار خواهد بود و آن کنش به‌عنوان سیاست تمام استیت‌ها انتخاب می‌شود. با این حال، با توجه به بخش الف می‌دانیم که سیاست بهینه در مثال استیت‌های  $(3, 2)$  و  $(2, 2)$  یکسان نمی‌باشد؛ از این‌رو این بدین معناست که الگوریتم Approximate Q-learning با استفاده از این فیچر‌ها نمی‌تواند همگرا شود و به سیاست بهینه برسد.

پرسش ۵ (۱۵ نمره)

شما یک شبکه عصبی دو لایه دارید که برای طبقه‌بندی حیوانات آموزش داده شده است. بردار ویژگی ورودی  $\vec{x} = [x_1, x_2, x_3, 1]$  است؛ در آن  $x_1, x_2, x_3$  ویژگی‌ها هستند و عدد ۱ نقش بایاس را دارد. دو گره پنهان و سه گره خروجی داریم و خروجی شبکه  $\vec{y}^* = [y_1^*, y_2^*, y_3^*]$  متناظر با سه کلاس خروجی است؛ به طوری که  $y_1^* = \text{Pr}(\text{dog} | \vec{x})$ ،  $y_2^* = \text{Pr}(\text{cat} | \vec{x})$  و  $y_3^* = \text{Pr}(\text{skunk} | \vec{x})$ . لایه پنهان از سیگموید (sigmoid) و لایه خروجی از سافت مکس (softmax) استفاده می‌کند.

- (آ) (۵نمره) يك توله سگ مالتيز بردار ويژگي  $\vec{x} = [۲, ۲۰, -۱, ۱]^T$  دارد. فرض كنيد همه وزن ها و باياس ها در ابتدا صفر هستند.  $\vec{y}^*$  را به دست آوريد.
- (ب) (۱۰نمره) فرض كنيد  $w_{ij}$  وزني باشد كه گره خروجي  $i$  ام را به گره پنهان  $j$  ام وصل مي كند. مشتق  $\frac{\partial y_j^*}{\partial w_{r1}}$  را به دست آوريد. پاسخ را بر حسب  $y_i^*$ ،  $w_{ij}$  و توابع فعال سازي  $h_j$  براي مقادير مناسب  $i$  و  $j$  بيان كنيد.

پاسخ

(آ) اگر تمام وزن ها و باياس ها صفر باشند، آنگاه خروجی هر گره پنهان برابر است با

$$۰ \times ۲ + ۰ \times ۲۰ + ۰ \times (-۱) + ۰ \times ۱ = ۰$$

با ورودی صفر، مقدار سیگمويد برابر  $\frac{1}{1+\exp(-f)} = \frac{1}{1+\exp(۰)} = ۰/۵$  می شود؛ اما چون وزن های لایه آخر نیز همگی صفرند، خروجی های لایه آخر نیز همگی صفر می شوند. با عبور از تابع فعال سازی softmax، هر گره خروجی مقدار

$$\frac{\exp(۰)}{\sum_{i=1}^r \exp(۰)} = \frac{1}{r}$$

را محاسبه می کند. پس  $\mathbf{y}^* = \begin{bmatrix} \frac{1}{r} \\ \frac{1}{r} \\ \frac{1}{r} \end{bmatrix}$  می باشد.

(ب) نماد  $f_i$  را به عنوان مقدار گره خروجی  $i$ -ام در نظر بگیرید. در این صورت، softmax را می توان به شکل زیر نوشت:


$$y_r^* = \frac{\exp(f_r)}{\sum_{j=1}^r \exp(f_j)}, \quad f_j = \sum_i w_{ji} h_i.$$

آنگاه:

$$\begin{aligned} \frac{dy_r^*}{dw_{r1}} &= \frac{1}{\sum_{i=1}^r \exp(f_i)} \frac{d \exp(f_r)}{dw_{r1}} + \exp(f_r) \frac{d}{dw_{r1}} \left( \frac{1}{\sum_{i=1}^r \exp(f_i)} \right) \\ &= \frac{1}{\sum_{i=1}^r \exp(f_i)} \exp(f_r) \frac{df_r}{dw_{r1}} + \exp(f_r) \left( -\frac{1}{(\sum_{i=1}^r \exp(f_i))^2} \right) \frac{d}{dw_{r1}} \left( \sum_{i=1}^r \exp(f_i) \right) \\ &= \frac{\exp(f_r)}{\sum_{i=1}^r \exp(f_i)} h_1 - \frac{\exp(f_r)}{(\sum_{i=1}^r \exp(f_i))^2} \frac{d \exp(f_r)}{dw_{r1}} \\ &= \frac{\exp(f_r)}{\sum_{i=1}^r \exp(f_i)} h_1 - \frac{\exp(f_r)}{(\sum_{i=1}^r \exp(f_i))^2} \exp(f_r) \frac{df_r}{dw_{r1}} \\ &= \frac{\exp(f_r)}{\sum_{i=1}^r \exp(f_i)} h_1 - \frac{\exp(2f_r)}{(\sum_{i=1}^r \exp(f_i))^2} h_1 \\ &= y_r^* h_1 - (y_r^*)^2 h_1. \end{aligned}$$

در گام سوم از این واقعیت استفاده شده که  $\frac{df_r}{dw_{r1}} = h_1$  (زیرا  $f_r = \sum_i w_{ri} h_i$ ) و هنگام مشتق گیری از  $\sum_i \exp(f_i)$  تنها جمله متناظر با  $f_r$  به  $w_{r1}$  وابسته است.

پرسش ۶ (۱۸ نمره) یک شبکه ی عصبی به کمک تابع فعالسازی پله طراحی کنید که به ازای نقاط درون ناحیه مشخص شده +1 و در غیراینصورت 0 خروجی دهد. (فرض کنید ورودی های شبکه  $x, x^2, y, y^2$  هستند).



پاسخ ناحیه مشخص شده برابر است با تفاضل یک دایره و یک لوزی

