

(۱) آ نادرست. الزاماً همواره درست نیست. ممکن است با داده های تست نیز تطابق داشته باشد و خطا در تست نیز کاهش یابد.

درواقع ممکن است داده های آموزش، نویزی در تضاد با داده های تست نداشته باشد.

(ب) درست. اگر bias مدل زیاد باشد، یعنی مدل بسیار ساده است و نمی تواند الگوهای پیچیده ی موجود در داده ها را به درستی

یاد بگیرد و افزایش تعداد داده های آموزشی تأثیر چندانی در کاهش bias ندارد، چون مدل اساساً نمی تواند روابط پیچیده را

یاد بگیرد؛ حتی اگر داده های بیشتری داشته باشد، باز هم به همان صورت ساده آن ها را مدل سازی می کند.

(ج) نادرست. طبقه بندی حالت خاصی از رگرسیون نیست.

(د) نادرست. الزاماً اینطور نیست و ممکن است مجدداً برچسب غلط پیش بینی شود. مثال: $(y_i = -1)$



(۲) آ بله، به صورتی خطی جدا پذیر اند. چون δ آن مثبت است. مثال خط جدا کننده: $f_7 + f_8 - 3$


(ب) در اولین مشاهده حاصل 1 است که بزرگتر از 0 است و A خروجی می دهیم که صحیح است پس بردار وزن تغییری

نمیکند. پس از اولین مشاهده: $(bias: 1, f_8: 0, f_7: 0)$

در دومین مشاهده حاصل 1 است که بزرگتر از 0 است و A خروجی می دهیم که صحیح نیست و بردار وزن با $(-1, -1, -1)$

جمع میشود. پس از دومین مشاهده: $(bias: 0, f_8: -1, f_7: -1)$

(ج) - بله: $(f_8: 1, f_7: 1, bias: -7)$ - خیر - خیر - خیر



A\Y	0	1
0	$\frac{1}{4}$	$\frac{4}{6}$
1	$\frac{3}{4}$	$\frac{2}{6}$

B\Y	0	1
0	$\frac{2}{4}$	$\frac{1}{6}$
1	$\frac{2}{4}$	$\frac{5}{6}$

C\Y	0	1
0	$\frac{0}{4}$	$\frac{3}{6}$
1	$\frac{4}{4}$	$\frac{3}{6}$

(آ)

$$Y=0 \sim: \frac{4}{10} * \frac{3}{4} * \frac{2}{4} * \frac{0}{4} = 0$$

$$Y=1 \sim: \frac{6}{10} * \frac{2}{6} * \frac{5}{6} * \frac{3}{6} = \frac{1}{12}$$

تناسب احتمال مشاهده چنین رکوردی در صورت نادرست بودن Y برابر صفر، و در صورت درست بودن Y برابر $\frac{1}{12}$ است.

بنابراین در طبقه بندی درست قرار می گیرد.

(ب)

$$Y=0 \sim: \frac{4}{10} * \frac{1}{4} * \frac{2}{4} * \frac{4}{4} = \frac{1}{20}$$

$$Y = 1 \sim: 6/10 * 4/6 * 1/6 * 3/6 = 1/30$$

نادرست $1/20 > 1/30$ بنابراین:

(ج)

$$Y = 0 \sim: \frac{4+1}{10+2} \times \frac{1+1}{4+2} \times \frac{2+1}{4+2} \times \frac{0+1}{4+2} = \frac{5}{432}$$

$$Y = 1 \sim: \frac{6+1}{10+2} \times \frac{4+1}{6+2} \times \frac{1+1}{6+2} \times \frac{3+1}{6+2} = \frac{35}{768}$$

درست

(د) طبقه بندی فعلی: نادرست

$$Y = 0 \sim: \frac{4}{10} \times \frac{3}{4} \times \frac{2}{4} \times \frac{4}{4} = \frac{3}{20}$$

$$Y = 1 \sim: \frac{6}{10} \times \frac{2}{6} \times \frac{1}{6} \times \frac{3}{6} = \frac{1}{60}$$

برای رسیدن به این هدف، بهترین رکوردی که میتوانیم اضافه کنیم، همین مقادیر a, b, c را دارد و مقدار Y آن درست است.

در آن صورت خواهیم داشت:

$$Y = 0 \sim: \frac{4}{11} \times \frac{3}{4} \times \frac{2}{4} \times \frac{4}{4} = \frac{3}{22}$$

$$Y = 1 \sim: \frac{7}{11} \times \frac{3}{7} \times \frac{2}{7} \times \frac{4}{7} = \frac{24}{539}$$

حتی در این صورت هم جواب هنوز نادرست است. بنابراین نمیتوان با افزودن تنها یک رکورد، طبقه بندی را تغییر داد.

(۴) بیشترین IG معادل است با کمترین $H(Y|X)$:

$$H(Y|A) = -\left(\frac{5}{10} \left(\frac{4}{5} \log \frac{4}{5} + \frac{1}{5} \log \frac{1}{5}\right) + \frac{5}{10} \left(\frac{3}{5} \log \frac{3}{5} + \frac{2}{5} \log \frac{2}{5}\right)\right) \cong 0.8464$$

$$H(Y|A) = \frac{1}{2} (0.72 + 0.97) = 0.845$$

$$H(Y|B) = -\left(\frac{7}{10} \left(\frac{5}{7} \log \frac{5}{7} + \frac{2}{7} \log \frac{2}{7}\right) + \frac{3}{10} \left(\frac{2}{3} \log \frac{2}{3} + \frac{1}{3} \log \frac{1}{3}\right)\right) \cong 0.8796$$

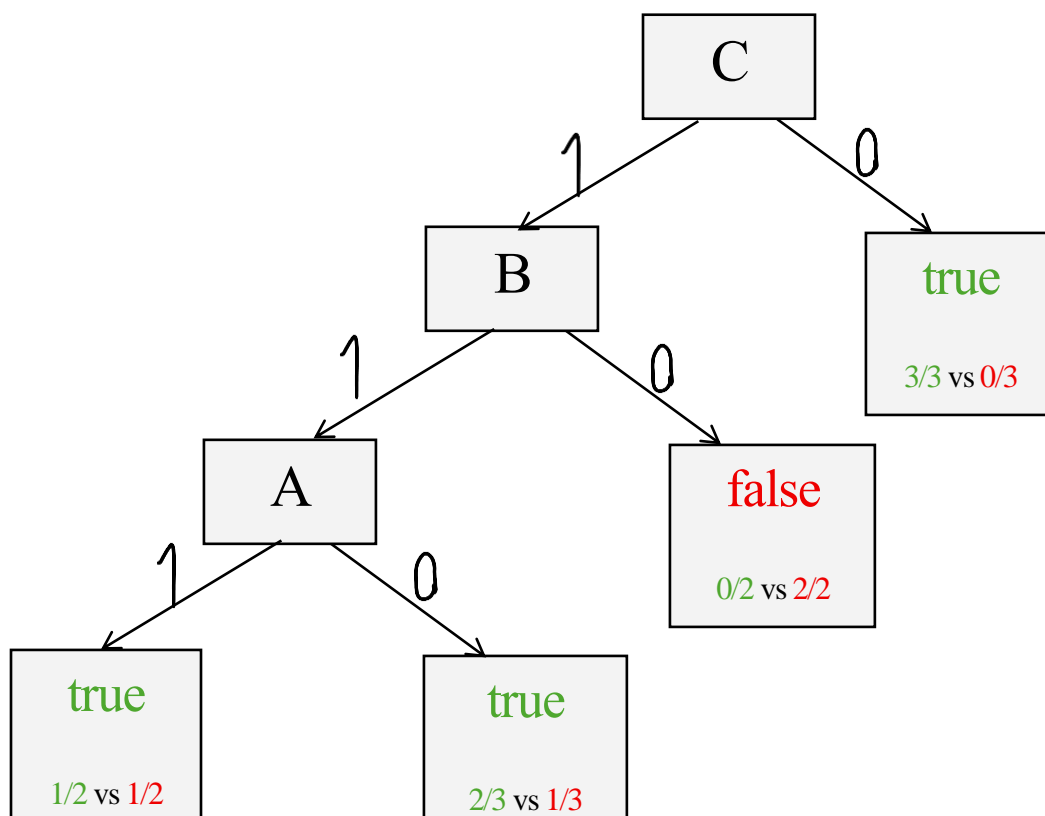
$$H(Y|B) = \frac{3}{10} * 0.92 + \frac{7}{10} * 0.86 = 0.878$$

$$H(Y|C) = -\left(\frac{7}{10} \left(\frac{4}{7} \log \frac{4}{7} + \frac{3}{7} \log \frac{3}{7}\right) + \frac{3}{10} \left(\frac{3}{3} \log \frac{3}{3}\right)\right) \cong 0.6894$$

$$H(Y|C) = \frac{7}{10} * 0.99 + \frac{3}{10} * 0.00 = 0.693$$

بنابراین C بیشترین IG را دارد.

(ب)




میتوان به جای گره A، true گذاشت.

ج (۱) false

ز (۲) true

د (۵) درخت به این شکل می شود:



ج (۱) false

ز (۲) true

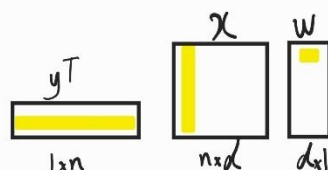
$$1*1 + 0*0 + 0*-1 + 1*1 + 1 = 3 \rightarrow 1$$

ب) ۱) اگر در مورد تصمیم گیری درون یک برگ صحبت کنیم، درست است. اما اگر تصمیم گیری در حالت کلی را بررسی کنیم، نادرست است. چون ۴ برگ داریم، در حالت کلی به کمک ۴ خط مختلف تصمیم گیری می شود و تصمیم گیری کلی مانند مدل پرسپترون صرفاً یک خط نیست.

۲) نادرست، تصمیم گیری در برگ ها در درخت پرسپترون نسبت به درخت تصمیم دقیق تر است و احتمال underfit شدن آن کمتر است.

ج)

- نادرست، اولی به کمک آنتروپی انتخاب میشود و دومی با training error rate و نتیجه الزاماً یکسان نیست.
- نادرست، از آنجا که راس های متفاوتی میتوانند انتخاب شوند، رسیدن به Training Error صفر میتواند با مسیرهایی با طول متفاوت انجام شود.
- درست، چون نهایتاً Training Error هر دو درخت صفر است.
- نادرست، اگر ورودی از training data ما نباشد، چنین تضمینی وجود ندارد و از آنجا که مدل ها متفاوت اند، میتوانند به ازای ورودی یکسان، خروجی متفاوت داشته باشند.
- نادرست، الزامی به انجام این کار وجود ندارد.

$$\begin{aligned}
 J_{\lambda} &= \frac{1}{r} (y - Xw)^T (y - Xw) + \lambda |w| \\
 &= \frac{1}{r} y^T y + \frac{1}{r} \underbrace{w^T X^T X w}_I - \frac{1}{r} \underbrace{w^T X^T y}_{|x|} - \frac{1}{r} \underbrace{y^T X w}_{|x|} + \lambda |w|
 \end{aligned}$$


$$\Rightarrow g(y) = \frac{1}{r} y^T y, \quad f = \frac{1}{r} w_i^2 + \lambda |w_i| - (y^T X_{:,i}) w_i$$

مقدار $g(y)$ که فارغ از X و w مشخص است و در کمینه کردن تابع نقشی ندارد. در بخش تابع f درایه i ام بردار w تنها با ویژگی i ام ارتباط دارد. (چون در $y^T X_{:,i}$ ضرب می شود و ستون i ام ماتریس X تنها شامل ویژگی i ام است.)

(ب)

$$\begin{aligned}
 &\text{if } w_i > 0 \rightarrow \\
 &w_i = \arg \min_{w_i} \underbrace{w_i \left(\frac{w_i}{r} + \lambda - y^T X_{:,i} \right)}_{h(w_i)} \\
 &h(w_i) = w_i \left(\frac{w_i}{r} - w_i \right) \\
 &= -\frac{w_i^2}{r} < 0 \leftarrow (w_i > 0) \\
 &\frac{d}{dw_i} h(w_i) = w_i + \lambda - y^T X_{:,i} = 0 \rightarrow w_i = y^T X_{:,i} - \lambda \quad (w_i = 0) \Rightarrow h(w_i) = 0 \\
 &w_i = \max(0, y^T X_{:,i} - \lambda)
 \end{aligned}$$

(ج)

$$w_i = \arg_{w_i} \min \underbrace{\frac{w_i^2}{2} - \lambda w_i - (y^T x_{:,i}) w_i}_{h(w_i)}$$

$$\frac{d}{dw_i} h(w_i) = w_i - \lambda - y^T x_{:,i} = 0 \rightarrow w_i = \lambda + y^T x_{:,i}$$

$$w_i = \min(\lambda + y^T x_{:,i}, -\epsilon)$$

مقدار بسیار کوچک منفی

(د)

در صورتی که $\lambda > y^T x_{:,i}$ باشد

یا $\lambda + y^T x_{:,i} > 0$ باشد

یعنی $\lambda > -y^T x_{:,i}$

اعمال: $\lambda > |y^T x_{:,i}|$

$$\begin{aligned} \frac{d}{dw_i} f &= w_i(\lambda+1) - y^T \mathcal{X}_{:,i} = 0 \\ w_i &= \frac{y^T \mathcal{X}_{:,i}}{\lambda+1}, \quad f = \sum_i w_i^2 (\lambda+1) \\ &\left(\lim_{\lambda \rightarrow \pm\infty} w_i = 0 \right) \\ y^T \mathcal{X}_{:,i} = 0 &\Rightarrow w_i = 0 \end{aligned}$$

در حالت قبل میتوانستیم با تنظیم مقدار λ وزن یک ویژگی را صفر مطلق کنیم. در حالی که در اینجا میتوان با بردن λ به سمت $\pm\infty$ وزن را به سمت صفر میل داد.

$$f(w, x) = \frac{1}{1 + e^{-(-2+4-3)}} = \frac{1}{1 + e^{-1}} = \frac{e}{1 + e} = 0.731$$

خروجی گره‌ها را به ترتیب از چپ به راست شماره گذاری کنیم.

$$n_1 = w_0 x_0 = -2, \quad n_2 = w_1 x_1 = 4, \quad n_3 = n_1 + n_2 = 2,$$

$$n_4 = n_3 + w_2 = 1, \quad n_5 = -1 \cdot n_4 = -1, \quad n_6 = e^{n_5} = 0.3679$$

$$n_7 = 1 + n_6 = 1.3679, \quad f = \frac{1}{n_7} = 0.7311$$

back prop:

$$\frac{\partial f}{\partial n_7} = \frac{-1}{n_7^2} = -0.534, \quad \frac{\partial n_7}{\partial n_6} = 1, \quad \frac{\partial n_6}{\partial n_5} = e^{-1},$$

$$\frac{\partial n_5}{\partial n_4} = -1, \quad \frac{\partial n_4}{\partial n_3} = 1, \quad \frac{\partial n_3}{\partial n_2} = 1, \quad \frac{\partial n_3}{\partial n_1} = 1$$

به کمک ضرب عملیات بالا داریم:

$$\frac{\partial f}{\partial x_0} = \frac{\partial f}{\partial n_1} \cdot \frac{\partial n_1}{\partial x_0} = 0.3934$$

$$\frac{\partial f}{\partial w_0} = \frac{\partial f}{\partial n_1} \cdot \frac{\partial n_1}{\partial w_0} = -0.1947$$

$$\frac{\partial f}{\partial x_1} = \frac{\partial f}{\partial n_2} \cdot \frac{\partial n_2}{\partial x_1} = -0.5901$$

$$\frac{\partial f}{\partial w_1} = \frac{\partial f}{\partial n_2} \cdot \frac{\partial n_2}{\partial w_1} = -0.3934$$

$$\frac{\partial f}{\partial w_2} = \frac{\partial f}{\partial n_4} \cdot \frac{\partial n_4}{\partial w_2} = 0.1947$$

(أ) 1

2 .I

3 .II

4 .III

5 .IV

4 .V

3 .VI

5 .output

(ب)

$$\frac{\partial y}{\partial a} = \frac{\partial y}{\partial s_1} \times \frac{\partial s_1}{\partial a} =$$

$$1 \times \frac{r_1 \cdot e^{-a \cdot r_1}}{(1 + e^{-a \cdot r_1})^2} = \frac{r_1 e^{-r_1}}{(1 + e^{-r_1})^2} \approx 0,11$$

$$\frac{\partial y}{\partial b} = \frac{\partial y}{\partial s_1} \times \frac{\partial s_1}{\partial b} = \frac{r_1 e^{-b r_1}}{(1 + e^{-b r_1})^2} = 0$$

$$\frac{\partial r_1}{\partial c} = \kappa_1 = 1, \quad \frac{\partial r_1}{\partial e} = \kappa_r = -1$$

$$\frac{\partial r_2}{\partial d} = 0, \quad \frac{\partial r_2}{\partial f} = 0$$

نحن max صغرا انتخاب كره.

$$\frac{\partial y}{\partial r_1} = \frac{\partial y}{\partial s_1} \cdot \frac{\partial s_1}{\partial r_1} = 1 \times$$

$$= \frac{e^{-r_1}}{(1 + e^{-r_1})^2} \approx 0,105$$

$$\frac{\partial y}{\partial r_2} = \frac{\partial y}{\partial s_1} \cdot \frac{\partial s_1}{\partial r_2} = 1 \times \frac{b e^{-b r_2}}{(1 + e^{-b r_2})^2} = \frac{e^0}{(1 + e^0)^2}$$

$$= \frac{1}{4}$$

$$\frac{\partial y}{\partial c} = \frac{\partial y}{\partial r_1} \cdot \frac{\partial r_1}{\partial c} = \frac{e^{-r_1}}{(1 + e^{-r_1})^2} \approx 0,105$$

$$\frac{\partial y}{\partial e} = \frac{\partial y}{\partial r_1} \cdot \frac{\partial r_1}{\partial e} = \frac{-e^{-r_1}}{(1 + e^{-r_1})^2} \approx -0,105$$

$$\frac{\partial y}{\partial d} = \frac{\partial y}{\partial r_2} \cdot \frac{\partial r_2}{\partial d} = 0$$

$$\frac{\partial y}{\partial f} = \frac{\partial y}{\partial r_2} \cdot \frac{\partial r_2}{\partial f} = 0$$

$$a = 1 - 0,11 = 0,89$$

$$b = 1$$

$$c = 1 - 0,105 = 0,895$$

$$d = 1$$

$$e = 1 - (-0,105) = 1,105$$

$$f = 1$$